

Çok Sınıflı (Multiclass) Görüntü Sınıflandırması için Konvolüsyonel Sinir Ağları (CNN) Kullanımı

Özet:

Görüntü sınıflandırma, bilgisayarla görü ve makine öğrenmesi alanlarında önemli bir problemdir. Son yıllarda, derin öğrenme teknikleri, özellikle Konvolüsyonel Sinir Ağları (CNN), görüntü sınıflandırma görevlerinde büyük başarılar elde etmiştir. Bu literatür çalışması, CNN'nin çok sınıflı görüntü sınıflandırmasındaki kullanımını incelemektedir. Farklı araştırmalar ve uygulamalar üzerinden CNN'nin başarısını, zorluklarını ve geliştirilmesi gereken alanları tartışarak, bu alandaki önemli katkıları özetleyecektir.

Anahtar Kelimeler: Çok sınıflı görüntü sınıflandırma (multiclass), Konvolüsyonel Sinir Ağları, Derin Öğrenme, Görüntü Sınıflandırma

1. Giriş

Görüntü sınıflandırma, bir görüntünün içerdiği nesneleri doğru şekilde tanımak ve etiketlemek amacıyla yapılan bir bilgisayarla görü görevidir. Son yıllarda, derin öğrenme yöntemlerinin, özellikle Konvolüsyonel Sinir Ağları (CNN), bu alanda önemli başarılar elde etmesine olanak sağlamıştır. CNN, görüntülerdeki öznitelikleri öğrenerek, daha önceki geleneksel yöntemlere kıyasla daha yüksek doğruluklar elde etmeyi başarmıştır [1]. Bu literatür çalışması, CNN'lerin çok sınıflı görüntü sınıflandırmasındaki kullanımını inceleyerek, bu alandaki gelişmeleri ve zorlukları ele alacaktır.

2. CNN'lerin Temel Yapısı ve Çalışma Prensipleri

Konvolüsyonel Sinir Ağları, görüntü işleme alanındaki en başarılı derin öğrenme modelleridir. CNN'ler, görüntü verilerini katmanlar aracılığıyla işleyerek, her katmanda öznitelik çıkarımı yaparlar. Bu ağlar, konvolüsyonel katmanlar, aktivasyon fonksiyonları, havuzlama katmanları ve tam bağlantılı katmanlardan oluşur. Bu yapılar, özellikle büyük veri kümeleriyle çalışırken önemli avantajlar sunar [2]. CNN'lerin başarısı, görüntüdeki mekansal bağımlılıkları etkili bir şekilde öğrenmesinden kaynaklanmaktadır.

3. Multiclass Sınıflandırma ve CNN

Çok sınıflı görüntü sınıflandırması, bir görüntüyü, belirli bir sınıfın birden fazla olası etiketinden birine yerleştirme problemidir. CNN, bu tür sınıflandırma görevlerinde geniş bir uygulama alanına sahiptir. Özellikle, ImageNet gibi büyük veri setlerinde eğitilmiş CNN modelleri, çok sınıflı görüntü sınıflandırmasında yüksek doğruluk oranları elde etmektedir. Ancak, çok sınıflı görüntü sınıflandırma görevlerinde sınıflar arasındaki benzerlikler, modelin başarısını zorlaştırabilmektedir [3].

4. Literatür İncelemesi

Birçok araştırma, CNN'lerin çok sınıflı görüntü sınıflandırmasındaki etkisini incelemiştir. Örneğin, He et al. (2016), ResNet modelini önererek, derin ağların eğitimini kolaylaştıran bir yapı geliştirmiştir [4]. Bunun yanı sıra, GoogLeNet [5] ve VGGNet [6] gibi modeller de çok sınıflı görüntü sınıflandırma alanında başarılı sonuçlar elde etmiştir.

Kimi araştırmalar ise, CNN'lerin çok sınıflı görüntü sınıflandırma görevlerinde daha verimli hale gelmesi için yeni teknikler önermektedir. Chen et al. (2018), transfer öğrenmeyi kullanarak, sınıflandırma doğruluğunu artırmayı başarmıştır [7]. Bunun yanında, veri artırma (data augmentation) ve erken durdurma (early stopping) gibi teknikler, CNN'lerin performansını iyileştirmede yaygın olarak kullanılmaktadır [8].

5. Zorluklar ve Geliştirilmesi Gereken Alanlar

CNN'lerin çok sınıflı sınıflandırma görevlerinde karşılaştığı bazı zorluklar da mevcuttur. Özellikle, büyük veri setlerinde eğitim süresi uzun olabilmekte ve fazla etiketli veriye ihtiyaç duyulmaktadır. Ayrıca, modelin aşırı uyum (overfitting) yapmaması için düzenleme yöntemlerinin doğru bir şekilde kullanılması gerekmektedir [9]. Ayrıca, bazı çalışmalar, çok sınıflı sınıflandırmada yanlış sınıflandırma oranlarının yüksek olabileceğine dikkat çekmiştir [10].

6. Sonuçlar

CNN, çok sınıflı görüntü sınıflandırma görevlerinde büyük bir ilerleme kaydetmiştir ve bu alanda çok sayıda başarılı model geliştirilmiştir. Ancak, modelin doğruluğunu artırmak için yeni teknikler ve yapılar geliştirilmesi gerekmektedir.

Kaynakça

- [1] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436-444, 2015.
- [2] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, 2012.
- [3] S. K. Ghosal and D. Bhattacharyya, "A survey of convolutional neural network based image classification techniques," *Int. J. Comput. Appl.*, vol. 152, pp. 18-23, 2017.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016.
- [5] C. Szegedy et al., "Going deeper with convolutions," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015.
- [6] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *Proc. Int. Conf. Learn. Representations*, 2015.
- [7] X. Chen et al., "Transfer learning for image classification with convolutional neural networks," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 29, no. 7, pp. 3191-3202, 2018.
- [8] S. Goodfellow, Y. Bengio, and A. Courville, "Deep Learning," MIT Press, 2016.

- [9] S. Ruder, "An overview of gradient descent optimization algorithms," *arXiv preprint arXiv:1609.04747*, 2016.
- [10] J. Redmon et al., "You only look once: Unified, real-time object detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016.